SVEUČILIŠTE U ZAGREBU

FAKULTET ORGANIZACIJE I INFORMATIKE

V A R A Ž D I N

Tin Barbarić

Matej Jurić

Od statistike do prodaje: Kako igrači kreiraju marketinški učinak kluba

PROJEKT IZ KOLEGIJA:

„PRIMJENA UMJETNE INTELIGENCIJE U POSLOVANJU“

Mentorice:

Izv. prof. dr. sc. Dijana Oreški

Prof. dr. sc. Sandra Lovrenčić

Varaždin, 2025.

SVEUČILIŠTE U ZAGREBU

FAKULTET ORGANIZACIJE I INFORMATIKE

V A R A Ž D I N

Matej Jurić

Tin Barbarić

Studij: Informacijski i poslovni sustavi

OD STATISTIKE DO PRODAJE: KAKO IGRAČI KREIRAJU MARKETINŠKI UČINAK KLUBA

PROJEKTNI RAD

Mentorice:

Izv. prof. dr. sc. Dijana Oreški

Prof. dr. sc. Sandra Lovrenčić

Varaždin, lipanj 2025.

Sadržaj

Sadržaj iii
1. Uvod 1
2. Razumijevanje domene 2
3. Razumijevanje podataka 3
3.1. Opis skupa podataka 3
3.2. Distribucija vrijednosti atributa 4
3.3. Provjera kvalitete podataka 5
4. Priprema podataka 6
4.1. Odabir podataka 6
4.2. Čišćenje podataka 6
4.3. Konstrukcija podataka 7
4.4. Integriranje podataka 7
Integracija nije bila potrebna jer nismo imali 2 skupa. 7
4.5. Oblikovanje podataka 7
5. Modeliranje 8
5.1. Odabir tehnike modeliranja 8
5.2. Dizajn testiranja 8
5.3. Izgradnja modela 9
5.4. Procjena modela 10
5.5. Analiza osjetljivosti 10
6. Vrednovanje 12
6.1. Evaluacija rezultata 12
6.2. Ocjenjivanje procesa 12
6.3. Određivanje sljedećih koraka 12
7. Korištenje 13
8. Zaključak 13
Popis literature 14
Popis slika 15

1. Uvod

U suradnji sa kolegicama i kolegama sa Ekonomije poduzetništva radili smo projekt usmjeren ka poboljšanju marketinške kampanje i strategije jednog bejzbolskog kluba. Naša strana priče (IPS) se bavila analizom podataka o profesionalnim bejzbol igračima, s ciljem da bolje razumijemo što najviše utječe na plaće bejzbol igrača. Projekt smo radili u sklopu kolegija „Primjena umjetne inteligencije u poslovanju“, gdje smo koristili metode strojnog učenja i analize podataka kako bismo otkrili obrasce koji se mogu iskoristiti za predviđanje vrijednosti igrača.

Radili smo s podacima za ukupno 322 igrača iz američkih bejzbol liga, a skup podataka sadrži 20-ak varijabli. Od napadačkih i obrambenih statistika, do iskustva i podataka o ligi/diviziji u kojoj igrač nastupa. Glavni cilj bio nam je otkriti koje karakteristike najviše utječu na plaću igrača (varijabla Salary, izražena u tisućama dolara).

Cijeli proces analize odrađen je u Google Colabu, što nam je olakšalo timski rad i pristup. Od biblioteka smo koristili Pandas za obradu podataka, Matplotlib i Seaborn za vizualizacije, te Scikit-learn za izradu i evaluaciju modela strojnog učenja.

Link na Google Collab:
https://colab.research.google.com/drive/1gWjxzU_acueaDrcXwspyLtdAEtJGRCWH?usp=sharing

2. Razumijevanje domene

Kako bismo bolje razumjeli kako se strojno učenje koristi u predikciji vrijednosti i plaća bejzbol igrača, proučili smo nekoliko recentnih stručnih i znanstvenih radova koji se bave sličnom tematikom:

1. Cheng-Yu Lee, Ping-Yu Hsu, Ming-Shien Cheng (2021.),
„Using Machine Learning to Predict Salaries of Major League Baseball Players“ [1]

Ovaj rad je direktno vezan uz našu temu jer autori također pokušavaju predvidjeti plaće igrača u MLB-u. Koristili su regresijske modele poput Lasso regresije i Ridge regresije te Random Forest i XGBoost, koji nam kasnije mogu poslužiti za naše modeliranje. Također koriste i bave se sličnim značajkama kao što su u našem skupu podataka.

2. Eric Au (2022.),
„Stepping Up To The Plate – Predicting MLB Player Value & Team Wins with Machine Learning“ [2]

Iako se ovaj rad ne fokusira isključivo na plaće, već na ukupnu vrijednost igrača i utjecaj na pobjede tima, pristup i algoritmi su vrlo slični. Koristio je Random Forest i Gradient Boosting, uz kombinaciju tradicionalnih i naprednih bejzbol metrika. Važno je što je autor istaknuo važnost konstrukcije novih značajki, njegovi nalazi su pokazali da dodatne, konstruirane značajke često povećavaju točnost predikcija.

3. Thomas Franco (2024.),
„Predicting Baseball Players' Value through Machine Learning: Traditional metrics vs Advanced metrics“ [3]

Thomas Franco je napravio usporedbu između tradicionalnih statistika (npr. Hits, RBI) i naprednih metrika (npr. WAR – Wins Above Replacement). Njegov rad bi nam mogao biti koristan jer pokazuje da čak i bez sofisticiranih naprednih metrika, moguće je napraviti kvalitetne predikcije ako se dobro selektiraju značajke i optimizira model. Također je radio na podosta sličnom skupu podataka i značajki.

3. Razumijevanje podataka

U ovom dijelu smo se bavili razumijevanjem podataka i shvaćanjem kako funkcioniraju te povezivanju podataka sa domenom koju smo ranije shvatili. Također možemo reći da je neki cilj ovog poglavlja bio približiti podatke vezane uz bejzbol našim kolegama i kolegicama sa Ekonomije poduzetništva kako bi oni kasnije lakše odlučili koji podaci odnosno značajke/atributi bi im mogli biti korisni za kriterije i alternative AHP metode.

3.1. Opis skupa podataka

Skup podataka koji koristimo u ovom projektu sadrži informacije o 322 profesionalna bejzbol igrača iz američkih liga. Uključuje 20 atributa, od kojih većina predstavljaju različite statistike učinka tijekom jedne sezone, ali i kroz cijelu karijeru. Osim numeričkih varijabli, skup sadrži i nekoliko kategoričkih (npr. liga i divizija u kojoj igrač nastupa). Ciljna varijabla koju želimo predviđati je plaća igrača, izražena u tisućama dolara.

Primjeri atributa uključuju: Broj udaraca (Hits), Broj Home Run-ova (HmRun), Broj asistencija u obrani (Assists), Godine iskustva (Years), te karijerne ukupne vrijednosti poput CHits, CRBI i CWalks.

Numeričke varijable su tipa int ili float, dok su kategoričke varijable (League, Division, NewLeague) tipa object.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 322 entries, 0 to 321
Data columns (total 20 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   AtBat      322 non-null    int64
 1   Hits       322 non-null    int64
 2   HmRun      322 non-null    int64
 3   Runs       322 non-null    int64
 4   RBI        322 non-null    int64
 5   Walks      322 non-null    int64
 6   Years      322 non-null    int64
 7   CAtBat     322 non-null    int64
 8   CHits      322 non-null    int64
 9   CHmRun     322 non-null    int64
 10  CRuns      322 non-null    int64
 11  CRBI       322 non-null    int64
 12  CWalks     322 non-null    int64
 13  League     322 non-null    object
 14  Division   322 non-null    object
 15  PutOuts    322 non-null    int64
 16  Assists    322 non-null    int64
 17  Errors     322 non-null    int64
 18  Salary     263 non-null    float64
 19  NewLeague  322 non-null    object
dtypes: float64(1), int64(16), object(3)
```

Slika 1 - Opis skupa podatka

3.2. Distribucija vrijednosti atributa

Analizom distribucija vidjeli smo da većina numeričkih varijabli ima pozitivnu asimetriju, što znači da većina vrijednosti ima tendenciju biti niža, uz manji broj vrlo visokih vrijednosti (outlier-a). To je posebno izraženo kod varijabli Salary, CHmRun i CRBI.

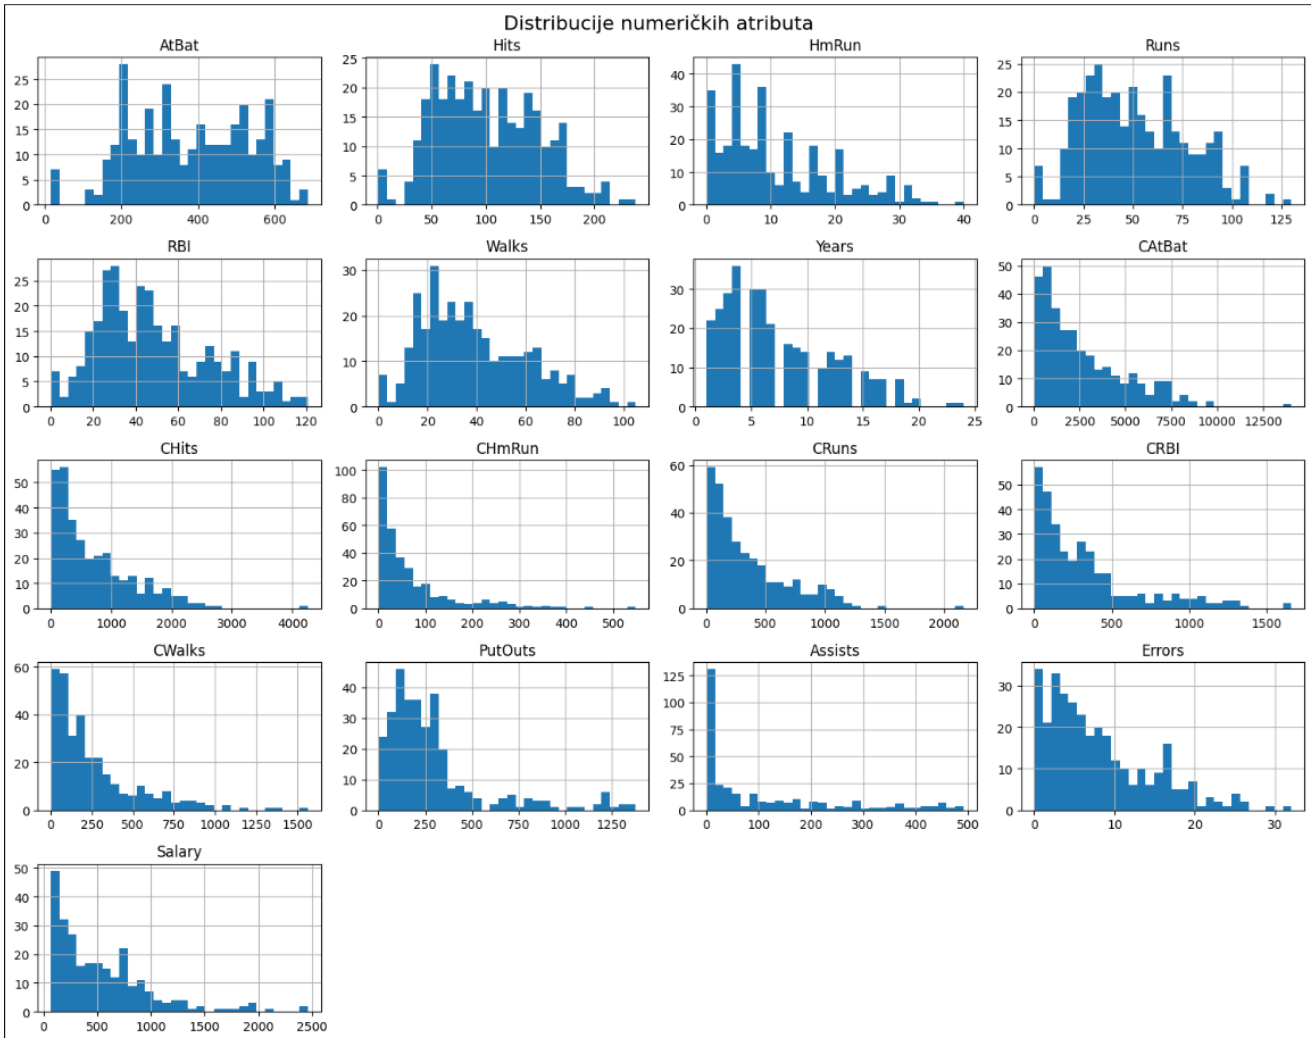

Slika 6 - Distribucija numeričkih atributa

Distribucije su prikazane pomoću histograma za sve numeričke varijable, a za kategoričke atribute (League, Division, NewLeague) koristili smo bar chartove. Rezultati pokazuju da su kategorije relativno uravnotežene, što je pozitivno za kasnije modeliranje.

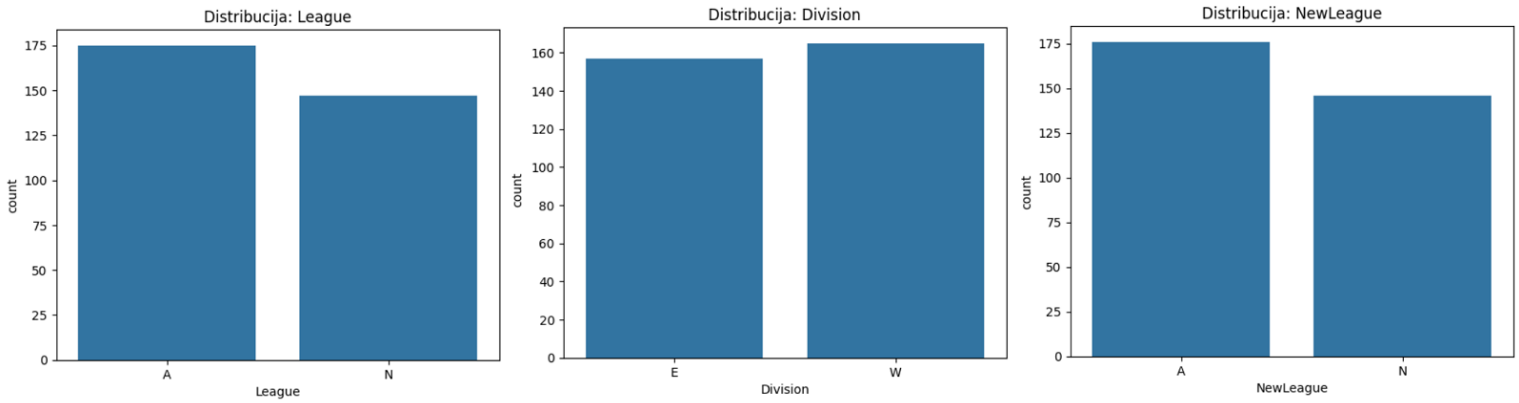

Slika 7 - distribucija kategoričkih atirubta

3.3. Provjera kvalitete podataka

U skupu podataka primijećene su nedostajuće vrijednosti u atributu Salary. Budući da je riječ o ciljnoj varijabli, ove redove bi u daljnjoj analizi mogli ukloniti. Provjerili smo i duplikate, ali nismo pronašli nikakve.

Nekoliko varijabli, kao što su Salary i CAtBat, pokazale su prisutnost izraženih outliera, što je potvrđeno i boxplot analizom. Ovi outlieri su očekivani jer u profesionalnom sportu često postoje velike razlike u plaćama i učinku igrača. Međutim, pri daljnjoj obradi podataka mogli bi smo to uzeti u obzir te primijenili skaliranje kako bi se ublažio njihov utjecaj.

4. Priprema podataka

4.1. Odabir podataka

Prije modeliranja analizirali smo odnose između varijabli kako bismo utvrdili postoji li multikolinearnost. Za tu svrhu napravili smo korelacijsku matricu, koja prikazuje međusobne koeficijente korelacije između svih numeričkih varijabli. Analiza je pokazala da su sezonske napadačke varijable poput CRBI, CHits, CRuns, CAtBat i CWalks međusobno vrlo snažno povezane, što jasno ukazuje na prisutnost multikolinearnosti unutar ovog skupa varijabli. Međutim, upravo te varijable pokazuju i najsnažniju pozitivnu korelaciju s ciljnom varijablom Salary. Što ih čini ključnim kandidatima za uključivanje u model.

Nasuprot tome, obrambene varijable poput PutOuts, Assists i Errors pokazuju znatno slabiju korelaciju s plaćom, pa su smatrane manje relevantnima za predikciju.

4.2. Čišćenje podataka

Uočili smo da jedino atribut Salary ima nedostajućih vrijednosti (59). Budući da se radi o ciljnoj varijabli, jednostavno smo odlučili izbaciti te redove jer bi popunjavanjem u ovom slučaju to bilo previše spekulativno. Također smo se pozabavili outlierima. Boxplot analiza je pokazala da Salary, CHmRun i CRBI imaju izražene ekstreme. Kako bi naš model bio otporniji, primijenili smo skaliranje na sve numeričke varijable prije treniranja modela.

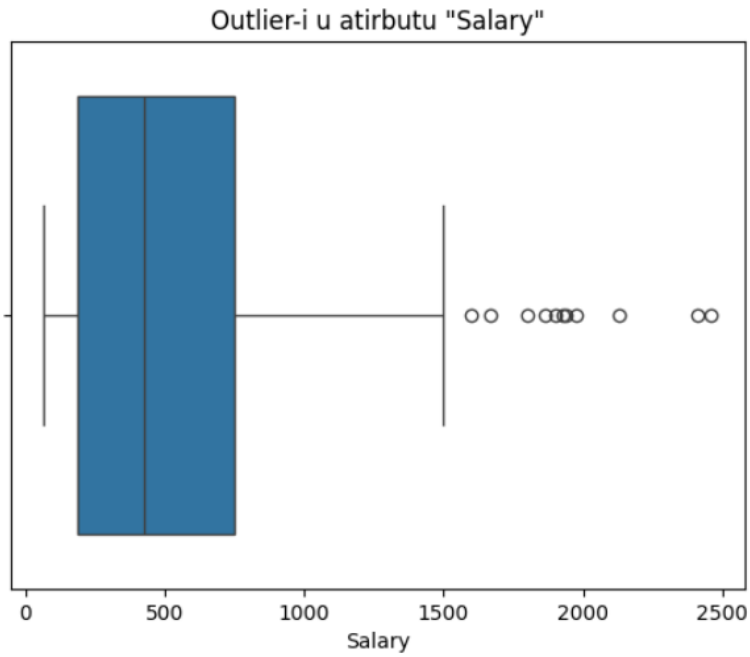

Slika 8 - Outlier-i u atributu Salary

4.3. Konstrukcija podataka

Dodali smo nekoliko novih atributa. Na primjer, kreirali smo omjer Home Run-ova po broju at-batova (HR_ratio = HmRun / AtBat), kao i omjer ukupnih udaraca kroz karijeru u odnosu na godine iskustva (CHits_per_Year). Ove konstruirane značajke omogućile su bolje razumijevanje učinkovitosti kroz vrijeme, ne samo apsolutne brojke.

4.4. Integriranje podataka

Integracija nije bila potrebna jer nismo imali 2 skupa ili nekih drugih potreba.

4.5. Oblikovanje podataka

Na kraju smo podatke pripremili za modeliranje. Kategoričke varijable (League, Division, NewLeague) smo enkodirali pomoću One hot encoder-a, a numeričke varijable skalirali pomoću StandardScaler-a. Pripremili smo i testni i trening skup (80:20 split) pomoću train_test_split() funkcije. Dataset je sada potpuno spreman za modeliranje.

5. Modeliranje

5.1. Odabir tehnike modeliranja

Prvo smo probali raditi sa Linearnom regresijom i XGBoost-om, ali kasnije smo se temeljem razgovora s AI alatom (u ovom slučaju ChatGPT-om), odlučili za LightGBM okvir storjnog učenja [7]. Odabrali smo LightGBM jer je vrlo učinkovit za nelinearne odnose, podržava regularizaciju, otporan je na outlier-e, automatski podržava Feature selekciju, i skalabilan je na većim podacima.

5.2. Dizajn testiranja

Za evaluaciju modela koristili smo 5-struku križnu validaciju koja je omogućila robusniju procjenu performansi. Na ovaj način smo izbjegli slučajne varijacije koje bi se mogle dogoditi pri samo jednoj podjeli skupa na trening i test.

5.3. Izgradnja modela

Model je implementiran u Scikit-learnu. Dali smo mu skalirane podatke i iterativno testirali performanse kroz različite vrijednosti hiperparametara. Koristili smo i Pipeline sa kojim osiguravamo da se svi koraci prije obrade podataka automatski primjenjuju prije treniranja ili predviđanja modela, kako bi svako treniranje bilo jedinstveno i dosljedno. Radili smo i sa optimizacijom hiperparametara (GridSeach), ali nismo vidjeli nikakva značajna poboljšanja pa smo model pustili na već postavljenim hiperparametrima. Na slici dolje vidimo skiciran izgled našeg modela (predprocesiranje, enkodiranje značajki i na kraju model, i sve te komponente zajedno u Pipeline-u kako bi se ponavljale).

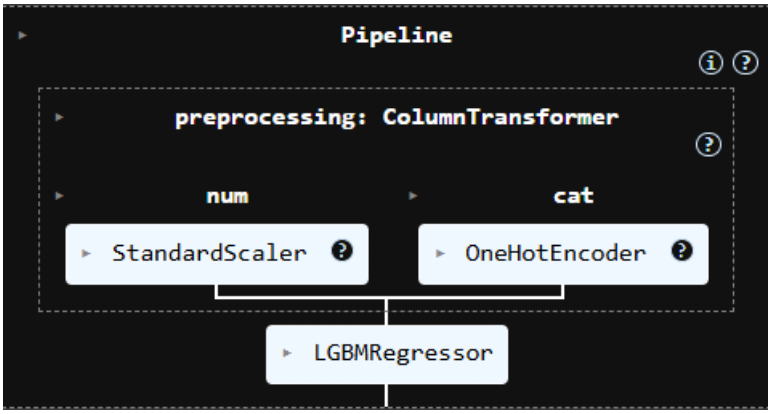

Slika 9 - Skica modela

5.4. Procjena modela

Kao prije spomenuto isprobani su modeli linearne regresije, XGBoost i LightGBM. Početni rezultati linearne regresije i XGBoost-a pokazali su nisku točnost i visoke RMSE vrijednosti. S obzirom na to, odabran je LightGBM.

Model je evaluiran pomoću 5-struke križne validacije. Rezultati su pokazali da LightGBM najbolje predviđa plaće igrača, a analiza važnosti atributa potvrdila je da napadačke statistike poput CRBI, CHits i CAtBat imaju najveći utjecaj na visinu plaće. Unatoč nepredvidivosti visine plaća, model je postigao zadovoljavajuće rezultate.Tako da smo zadovoljni sa dobivenim rezultatima evaluacije:

```
R² (train): 0.971925054260329
R² (test): 0.6127562494164136
```

Slika 10 – Evaluacija 01

```
MAE: 174.64848145542118
RMSE: 336.3872066103956
```

Slika 11 - Evaluacija 02

5.5. Analiza osjetljivosti

Analizom značajki u LGBM-u došli smo do zaključka da su najvažnije značajke: Chits, PowerIndex, CRBI... Num označava numeričke varijable u očišćenom dataset-u, da ne bi došlo do zabune. Ove značajke imaju najveću prediktivnu moć prema LightGBM modelu i najviše utječu na procjenu plaće. Vidimo da su pri vrhu većinom karijerne varijable (CHit i CRBI).

Model očito preferira kumulativne karijerne statistike ispred trenutne sezone, što sugerira da je kontinuitet performansi kroz karijeru ključan faktor kod određivanja plaće. PowerIndex je značajka koju smo dobili dijeljenjem CHmRun-a i CAtBat odnosno predstavlja omjer home runova u karijeri (CHmRun) i ukupnog broja izlazaka na palicu u karijeri (CAtBat). Vidimo kolika je njegova efikasnost kod udranja (od koliko udaraca igrač ostvari Home Run, koliko je pravovremen i snažan njegov udarac)

Tu je i PutOuts koji je tu s razlogom, ako je igrač ostavio više PutOuts-a (izbacio protivnički tim) tada taj igrač i zaslužuje imati veću plaću.

Kada smo analizirali koje su značajke najvažnije, vidjeli smo da najviše utječu ukupne statistike igrača iz cijele karijere (kao što su ukupan broj udaraca i ukupni broj bodova koje je igrač donio timu), te naši izračunati pokazatelji snage udarca (PowerIndex). To znači da naš model dobro prepoznaje koliko su važni dosadašnji uspjesi i stalnost igrača.

Sveukupno, jako smo zadovoljni jer smo uspjeli primijeniti naučeno znanje na pravim podacima. To nam je pomoglo da bolje shvatimo kako se radi predviđanje i modeli u poslovanju.

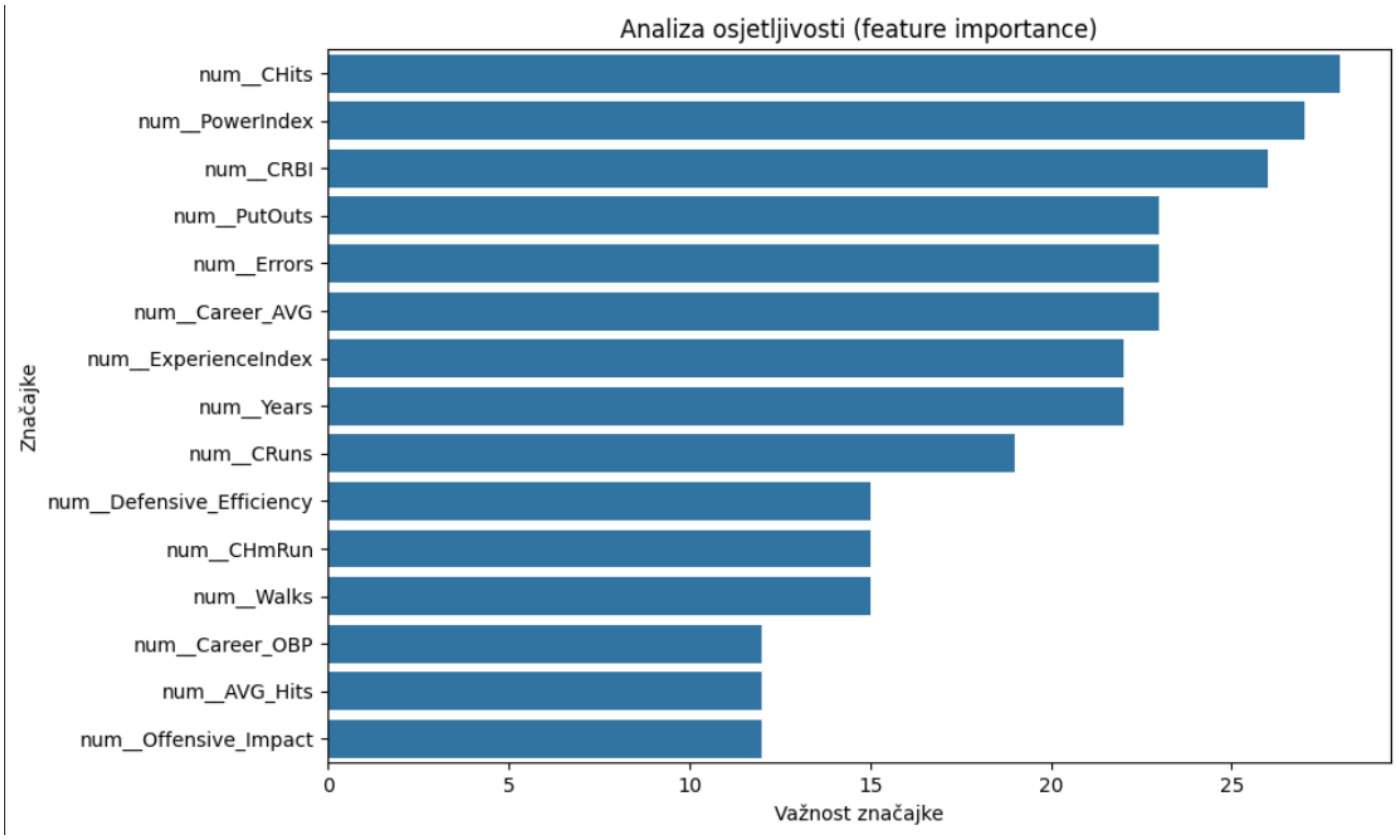

Slika 12 - značajke prema važnosti

6. Vrednovanje

6.1. Evaluacija rezultata

Rezultati su bili dosta ujednačeni između različitih modela, ali LGBM se istaknuo s najboljom točnošću. Važno je napomenuti da su modeli dobro hvatali opće trendove, no i dalje ima određenih outliera (npr. igrači s niskim statistikama, a visokom plaćom) koje je teško predvidjeti jer vjerojatno ovise o faktorima koje nemamo u podacima (npr. popularnost, ugovorne klauzule).

6.2. Ocjenjivanje procesa

Cijeli CRISP-DM proces nam je bio vrlo koristan jer smo strukturirano radili korak po korak, bez preskakanja. Odabrani algoritmi su zadovoljili pretpostavke, skup podataka je bio dovoljno velik i raznolik da se mogu donijeti koliko-toliko korisni zaključci.

6.3. Određivanje sljedećih koraka

Potencijalno poboljšanje bilo bi dodavanje naprednih metrika koje se koriste u sabermetrics analizi bejzbola (npr. WAR). Također bi mogli pokušati trenirati neuralnu mrežu za dublje učenje uz veći dataset. Korištenje shapley vrijednosti za interpretaciju modela također bi moglo biti korisno.

7. Korištenje

Kao završni korak, kolege i kolegice sa Ekonomije poduzetništva koristili su našu analizu i rezultate modela za određivanje težine kriterija u AHP metodi. Značajke koje su bile najvažnije u modelima (npr. CRBI, PutOuts, Years) postale su glavni kriteriji kod usporedbe alternativa za izgradnju marketinške strategije. Kroz zajednički rad osmislili su marketinšku strategiju koja cilja profile igrača s najvišom očekivanom vrijednošću, ali i dobrim omjerom cijene i performansi.

8. Zaključak

Kroz ovaj projekt imali smo priliku proći kroz cijeli CRISP-DM proces i vidjeti kako se znanje iz strojnog učenja može primijeniti u stvarnom poslovnom kontekstu – u ovom slučaju za bolje razumijevanje vrijednosti sportaša. Korištenjem različitih modela uspjeli smo izdvojiti značajke koje najviše utječu na plaće igrača, a kolege sa EP-a su na temelju toga razvili AHP tablicu i marketinšku strategiju.

Popis literature

[1] C.-Y. Lee, P.-Y. Hsu, and M.-S. Cheng, "Using Machine Learning to Predict Salaries of Major League Baseball Players," in Advances in Intelligent Systems and Computing, 2021. https://link.springer.com/chapter/10.1007/978-3-030-79463-7_3

[2] E. Au, "Stepping Up To The Plate - Predicting MLB Player Value & Team Wins with Machine Learning," Medium, 2022. https://medium.com/@eric8395/stepping-up-to-the-plate-predicting-mlb-player-value-team-wins-with-machine-learning-e9d38bbb0097

[3] T. Franco, "Predicting Baseball Players' Value through Machine Learning: 'Traditional metrics' vs 'Advanced metrics'," ResearchGate, 2024. https://www.researchgate.net/publication/382249191_Predicting_Baseball_Players%27_Value_through_Machine_Learning_Traditional_metrics_vs_Advanced_metrics

[4] S. Lundberg and S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," in Advances in Neural Information Processing Systems (NIPS), 2017. https://proceedings.neurips.cc/paper_files/paper/2017/file/8a20a8621978632d76c43dfd28b67767-Paper.pdf

[5] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, pp. 785–794. https://dl.acm.org/doi/10.1145/2939672.2939785

[6] Prezentacije i laboratorijske vježbe iz kolegija „Otkrivanje znanja u podacima“ i „primjena umjetne inteligencije u poslovanju“

[7] OpenAI, “ChatGPT” (2025), OpenAI. [Online]. Available: https://chat.openai.com/

Popis slika

Slika 1 - Opis skupa podatka 3
Slika 2 - Distribucija numeričkih atributa ..... **Error! Bookmark not defined.**
Slika 3 - distribucija kategoričkih atirubta ..... **Error! Bookmark not defined.**
Slika 4 - Outlier-i u atirbutu Salary ..... **Error! Bookmark not defined.**
Slika 5 - Skica modela 9
Slika 6 – Evaluacija 01 9
Slika 7 - Evaluacija 02 10
Slika 8 - značajke prema važnosti 11